DOCUMENTAÇÃO TÉCNICA · COMPARAÇÃO NA MESMA JANELA TEMPORAL DO ARTIGO

Köppen–Geiger via ERA5 1950–1990 — Comparação direta com Alvares et al. (2013)

Reclassificação do Brasil inteiro usando ERA5 reanalysis na **mesma janela temporal do artigo original** (1950–1990), com correção de viés por estações convencionais do INMET e investigação das causas residuais de divergência.

Período dos dados: janeiro/1950 a dezembro/1990 (41 anos — janela textual do artigo)

Fonte: ERA5 monthly averaged reanalysis (Copernicus CDS) + 405 estações convencionais BDMEP/INMET

Área: Brasil inteiro, recortado pela malha oficial do IBGE

Ferramentas: earthkit-data, xarray, geopandas, pykrige, scikit-learn, matplotlib

Sumário

1 Introdução e objetivo

2 Fonte de dados

2.1 ERA5 1950–1990 · 2.2 Estações convencionais BDMEP/INMET

3 Tecnologias usadas e por quê

4 Metodologia

4.1 Carregamento e alinhamento temporal · 4.2 Máscara do Brasil (IBGE) · 4.3 Climatologia mensal · 4.4 Algoritmo de Köppen–Geiger · 4.5 Correção de viés por krigagem

5 Verificação do algoritmo

6 Resultados

6.1 Análise exploratória · 6.2 Climatologia espacial · 6.3 Mapa de Köppen · 6.4 Comparação de quatro pontas

7 Correção de viés por estações convencionais

7.1 Resultado da correção · 7.2 Ganhos e perdas por tipo climático

8 Investigação: por que a correção não resolveu Am/Aw

9 Teste negativo: correção por taxa de lapso (altitude)

10 Limitações e ressalvas metodológicas

11 Referências

1. Introdução e objetivo

Este documento registra a quarta variante da análise exploratória de classificação climática de Köppen–Geiger para o Brasil, construída sobre o trabalho anterior (`notebook_brasil.ipynb`, ERA5 1996–2025) com um objetivo específico: **isolar a variável "período"** da variável "fonte de dado" na comparação com o artigo original de Alvares et al. (2013).

Os notebooks anteriores (ERA5 1996–2025 e estações automáticas BDMEP ~2000–2025) encontraram a mesma divergência frente ao artigo — zona B (árido/semiárido) maior, zona C (subtropical) menor — em duas fontes de dado independentes. Isso levanta duas hipóteses não excludentes: (1) viés sistemático de fonte de dado moderna, ou (2) mudança climática real entre a linha de base do artigo (1950–1990) e o período atual. Rodar o ERA5 exatamente na janela textual do artigo — *"adequate temporal data series (> 25 years between 1950 and 1990)"* — permite testar essas hipóteses diretamente: se o resultado bater com o artigo nessa janela, a hipótese (2) ganha força.

> **Resultado central adiantado:** a zona A bate quase perfeitamente com o artigo em todas as quatro fontes testadas (81,4% a 82,4%). A zona B mostra uma progressão temporal quase monotônica — 4,9% (artigo, 1950–1990) → 6,1% (ERA5 na mesma janela) → ~8% (dado moderno, ERA5 e estações) — evidência de que a divergência é predominantemente temporal, não um artefato puro de fonte de dado.

2. Fonte de dados

2.1 ERA5 1950–1990

Produto	`reanalysis-era5-single-levels-monthly-means`
Variáveis	`2m_temperature` (2t) e `total_precipitation` (tp)
Área (bbox)	lat 6°/-34°, lon -74°/-34° — Brasil inteiro + margem
Resolução	grade regular 0,25° (161×161 pontos)
Período	jan/1950 – dez/1990 (41 anos, 984 campos = 2 variáveis × 12 meses × 41 anos)

Uma particularidade de metadados exigiu tratamento especial: o campo `tp` é codificado com o tempo referenciado ao início da previsão (18h do dia anterior + passo de 12h), enquanto `2t` usa o tempo de validade direto (00h do dia 1). Isso fazia o `earthkit-data` recusar o merge automático das duas variáveis. A correspondência mês-a-mês entre as duas séries foi verificada como 1:1 antes de realinhar pela coordenada limpa do `2t` — sem alterar nenhum valor de dado, só a coordenada de tempo.

2.2 Estações convencionais BDMEP/INMET

Para testar correção de viés e investigar causas de divergência, foram usadas **646 estações convencionais** do INMET (código numérico de 5 dígitos, padrão OMM — rede histórica,

diferente da rede automática usada no `notebook_estacoes.ipynb`), baixadas manualmente do portal BDMEP para o período 1950–1990, mesmas variáveis (temperatura média mensal, precipitação total mensal). Após filtro de qualidade (≥5 anos de dado válido em **todo** mês-calendário, para evitar que uma estação com histórico curto distorça a climatologia), restaram **405 estações utilizáveis**.

3. Tecnologias usadas e por quê

earthkit-data + xarray

Mesma combinação dos notebooks anteriores: leitura do GRIB via earthkit, processamento N-dimensional (tempo/lat/lon) via xarray. Aqui foi necessário tratar manualmente o desalinhamento de metadados entre `2t` e `tp` (Seção 2.1), carregando cada variável separadamente antes do merge.

geopandas + shapely

Recorte do Brasil pela malha oficial do IBGE (ponto-em-polígono via `shapely.contains_xy`), igual ao `notebook_brasil.ipynb` — necessário porque a bbox do ERA5 inclui partes da Argentina, Bolívia, Paraguai, Peru, Colômbia, Venezuela e Guianas.

pykrige

Krigagem ordinária (modelo esférico, coordenadas geográficas) para espacializar o erro `ERA5 − estação` nos pontos de estação e interpolar essa superfície de correção sobre toda a grade do Brasil (regression-kriging aplicado como correção de viés, não como preenchimento de grade vazia — o ERA5 já é completo).

scikit-learn (LinearRegression)

Usado para testar se a altitude explica sistematicamente o erro do ERA5 (Seção 9, teste de correção por taxa de lapso) — resultado negativo, documentado com R^2 baixo para todos os preditores aplicáveis a uma correção de grade.

ETOPO 2022 (NOAA, via ERDDAP)

Modelo de elevação de 1 arc-minuto (~1,8 km), obtido via serviço público ERDDAP recortado para a bbox do Brasil (sem precisar baixar/mosaicar tiles SRTM), usado exclusivamente no teste de correção por altitude (Seção 9).

matplotlib

Todos os mapas e gráficos, incluindo os mapas de densidade de estação (distância à estação mais próxima) usados na investigação da Seção 8.

4. Metodologia

4.1 Carregamento e alinhamento temporal

Carregamento separado de `2t` e `tp`, verificação de correspondência mês-a-mês (ambas monotonicamente crescentes, 492 passos cada), realinhamento da coordenada de tempo de `tp` pela de `2t`, e só então merge. Conversão de unidades idêntica aos notebooks anteriores: `2t` em Kelvin → Celsius; `tp` em m/dia (taxa média diária) × dias do mês × 1000 → mm/mês.

4.2 Máscara do Brasil (IBGE)

Mesmo procedimento do `notebook_brasil.ipynb`: teste ponto-em-polígono (`shapely.contains_xy`) contra o polígono oficial do IBGE para cada célula da grade. Resultado: 11.346 de 25.921 células (43,8% da bbox) dentro do território brasileiro, cobrindo 8.530.545 km² — 0,24% de diferença frente aos 8.510.000 km² oficiais.

4.3 Climatologia mensal

Para cada célula e mês-calendário, média dos 41 anos (1950–1990), produzindo os arrays `T_arr` / `P_arr` (12, lat, lon) que alimentam a classificação.

4.4 Algoritmo de Köppen–Geiger

Função `koppen_classify` copiada, caractere por caractere, dos notebooks anteriores — nenhuma alteração de lógica. Mesma ordem de prioridade B→A→E→C/D, mesmos 15 testes sintéticos de verificação (Seção 5).

4.5 Correção de viés por krigagem

Para cada mês-calendário: (1) amostra-se o valor bruto do ERA5 no pixel mais próximo *válido* (dentro do território) de cada estação convencional — com fallback de busca em janela de 5 células para as 22 estações litorâneas cujo pixel bruto caía em oceano/fora do Brasil; (2) calcula-se o erro `ERA5 − estação` (temperatura: aditivo; precipitação: em escala `log1p`, para lidar com a assimetria da distribuição de chuva); (3) krigagem ordinária (modelo esférico, coordenadas geográficas) desse erro sobre todos os pontos de grade do Brasil; (4) subtração da superfície de erro interpolada da grade bruta.

5. Verificação do algoritmo

Os mesmos 15 perfis sintéticos (um por tipo climático, incluindo tipos que não ocorrem nos dados reais — Cwc, Csa, Csb, ET, EF, BWh) foram reexecutados para comprovar que o algoritmo é idêntico ao dos notebooks anteriores:

```
OK    esperado=Af   obtido=Af    Tcold= 27.0  Thot= 27.0  MAP= 2460mm  Pdry= 80mm
OK    esperado=Am   obtido=Am    Tcold= 27.0  Thot= 27.0  MAP= 2525mm  Pdry= 15mm
OK    esperado=Aw   obtido=Aw    Tcold= 26.0  Thot= 26.0  MAP= 1708mm  Pdry=  1mm
OK    esperado=As   obtido=As    Tcold= 26.0  Thot= 26.0  MAP= 1475mm  Pdry= 20mm
OK    esperado=BSh  obtido=BSh   Tcold= 26.0  Thot= 26.0  MAP=  510mm  Pdry=  1mm
OK    esperado=BWh  obtido=BWh   Tcold= 28.0  Thot= 28.0  MAP=   27mm  Pdry=  0mm
OK    esperado=Cfa  obtido=Cfa   Tcold= 13.0  Thot= 24.0  MAP= 1540mm  Pdry=110mm
OK    esperado=Cfb  obtido=Cfb   Tcold= 13.0  Thot= 20.5  MAP= 1460mm  Pdry= 80mm
OK    esperado=Cwa  obtido=Cwa   Tcold= 17.5  Thot= 23.5  MAP= 1415mm  Pdry= 15mm
OK    esperado=Cwb  obtido=Cwb   Tcold= 15.5  Thot= 21.5  MAP= 1424mm  Pdry= 10mm
OK    esperado=Cwc  obtido=Cwc   Tcold=  4.5  Thot= 11.5  MAP= 1260mm  Pdry= 15mm
OK    esperado=Csa  obtido=Csa   Tcold= 17.5  Thot= 22.7  MAP=  810mm  Pdry= 20mm
OK    esperado=Csb  obtido=Csb   Tcold= 17.0  Thot= 21.5  MAP=  810mm  Pdry= 20mm
OK    esperado=ET   obtido=ET    Tcold= -3.0  Thot=  5.0  MAP=  600mm  Pdry= 50mm
OK    esperado=EF   obtido=EF    Tcold= -5.0  Thot= -5.0  MAP=  360mm  Pdry= 30mm

15/15 casos corretos -- algoritmo idêntico aos outros notebooks
```

6. Resultados

6.1 Análise exploratória

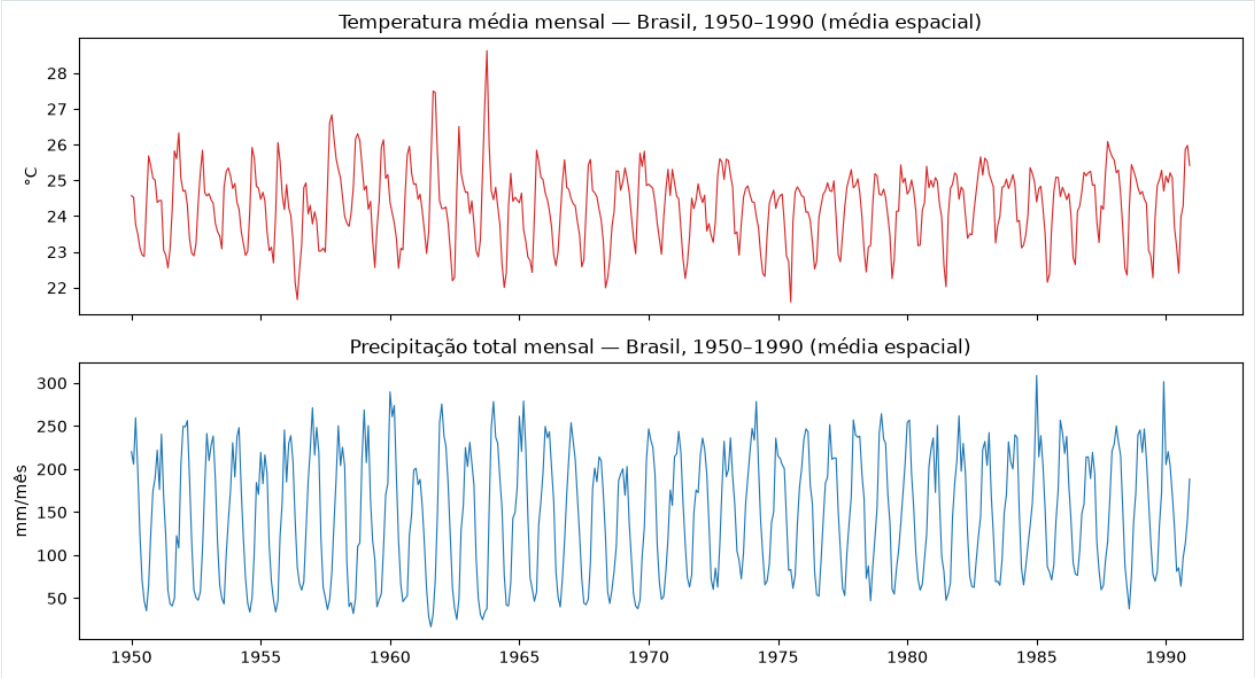


Figura 1. Temperatura e precipitação médias mensais do Brasil (média espacial), jan/1950 – dez/1990.

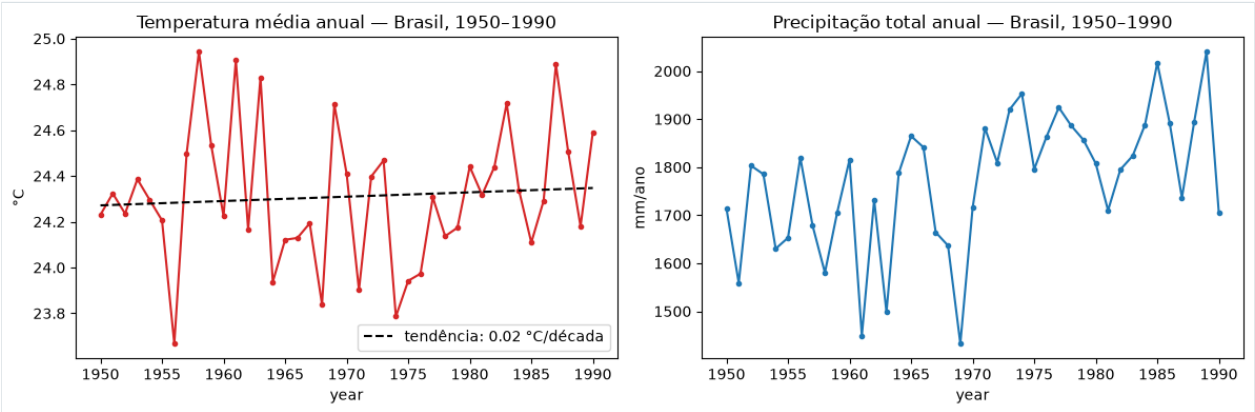


Figura 2. Temperatura média anual (com tendência linear) e precipitação total anual, ano a ano, 1950–1990.

6.2 Climatologia espacial

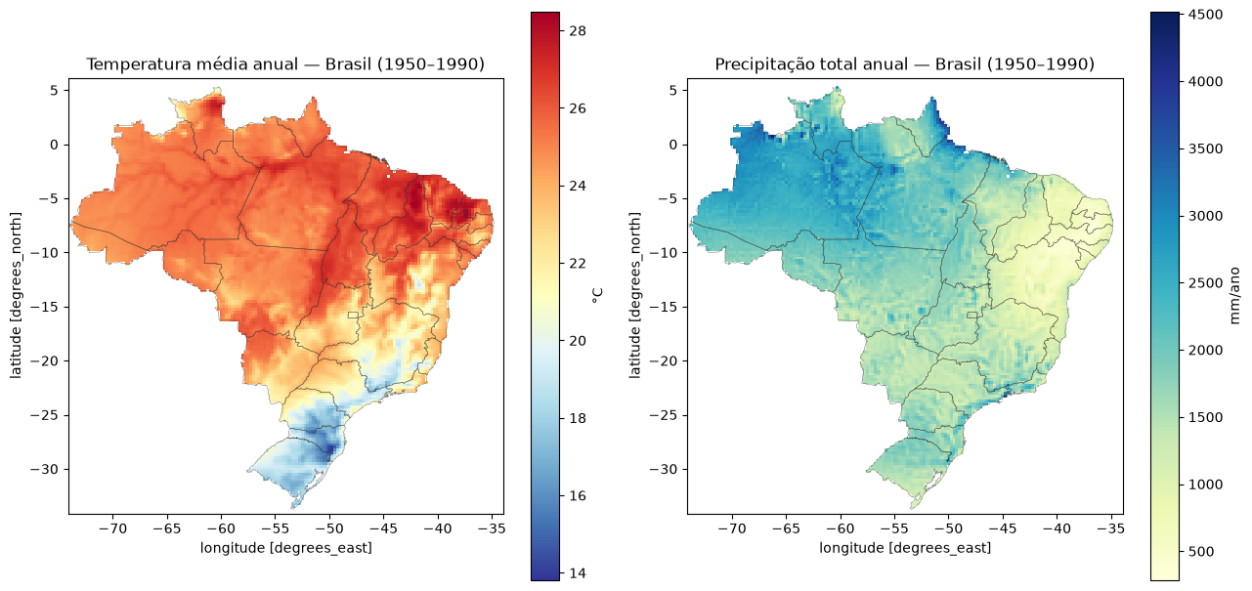


Figura 3. Temperatura média anual e precipitação total anual, climatologia 1950–1990, Brasil inteiro.

6.3 Mapa de classificação de Köppen

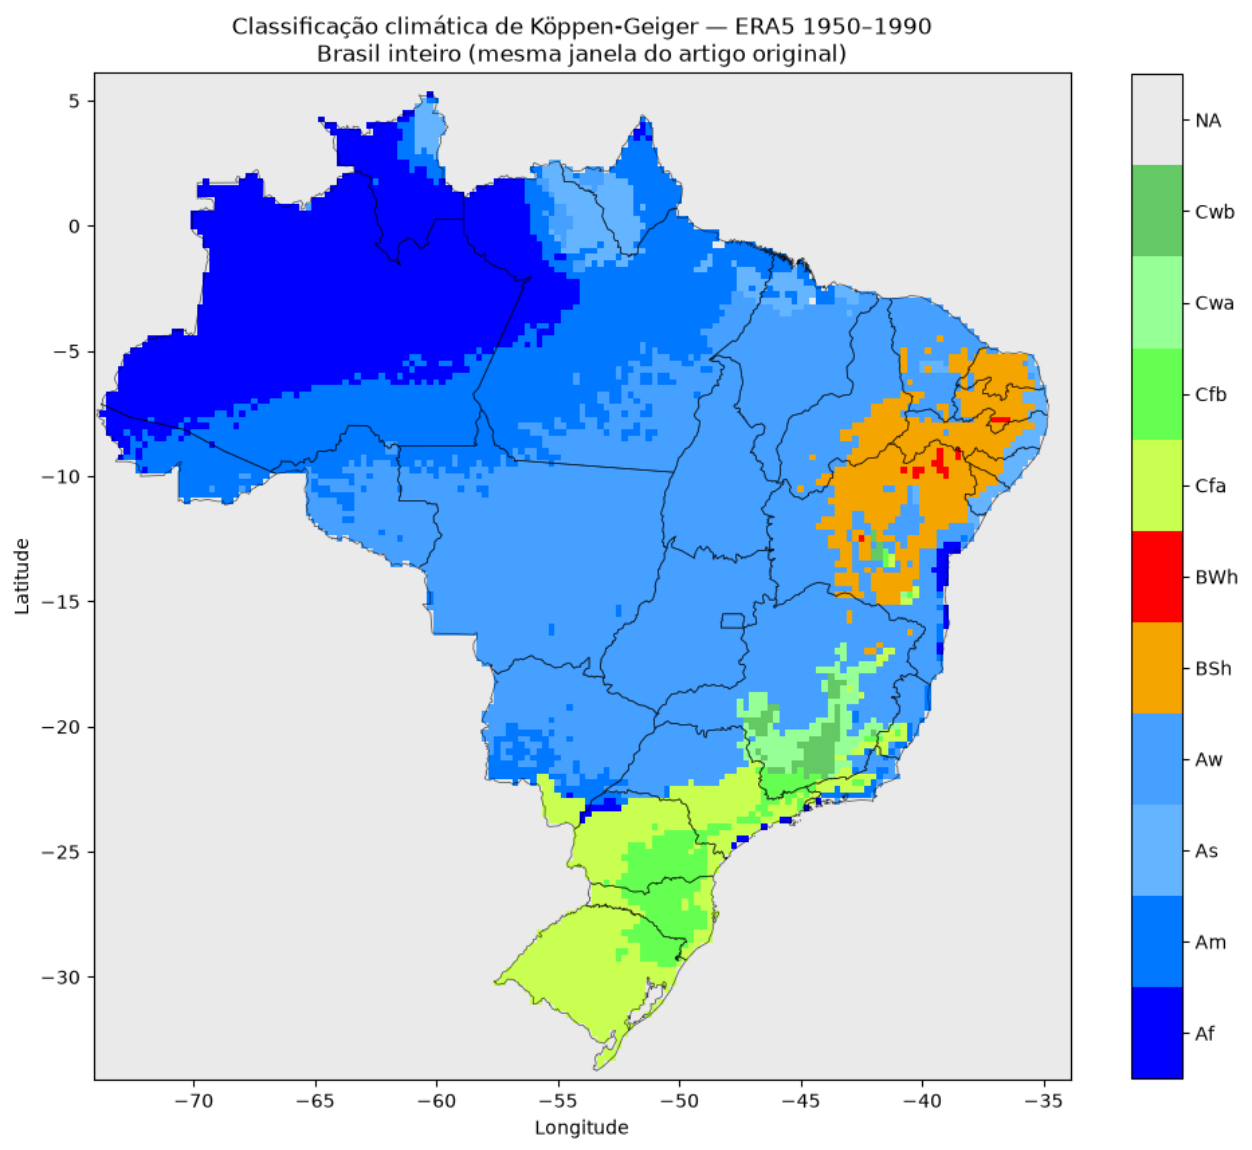


Figura 4. Classificação climática de Köppen–Geiger — ERA5 1950–1990, Brasil inteiro, mesma janela temporal do artigo original.

Distribuição percentual (11.346 células classificadas):

Clima	Nº de células	%
Aw	4.829	42,6%
Af	2.151	19,0%
Am	1.982	17,5%
Cfa	794	7,0%
BSh	670	5,9%
As	369	3,3%
Cfb	305	2,7%
Cwa	149	1,3%
Cwb	80	0,7%
BWh	17	0,1%

6.4 Comparação de quatro pontas (zonas A/B/C)

Comparação agregada por zona entre o artigo e as três fontes de dado modernas já analisadas (ERA5 1996–2025 e estações automáticas, de notebooks anteriores):

Zona	Artigo (1950–1990)	ERA5 1950–1990	ERA5 1996–2025	Estações ~2000–2025
A (tropical)	81,4%	**82,2%**	82,3%	82,4%
B (árido/semiárido)	4,9%	6,1%	8,2%	7,9%
C (subtropical)	13,7%	11,7%	9,5%	9,7%

> **Progressão temporal da zona B:** 4,9% → 6,1% → 8,2%/7,9% conforme a janela temporal avança de 1950–1990 para o presente — o ERA5 rodado exatamente na janela do artigo cai quase precisamente no meio do caminho entre o artigo e o dado moderno, evidência de tendência temporal real (expansão da área semiárida), não apenas viés de fonte de dado.

7. Correção de viés por estações convencionais

7.1 Resultado da correção

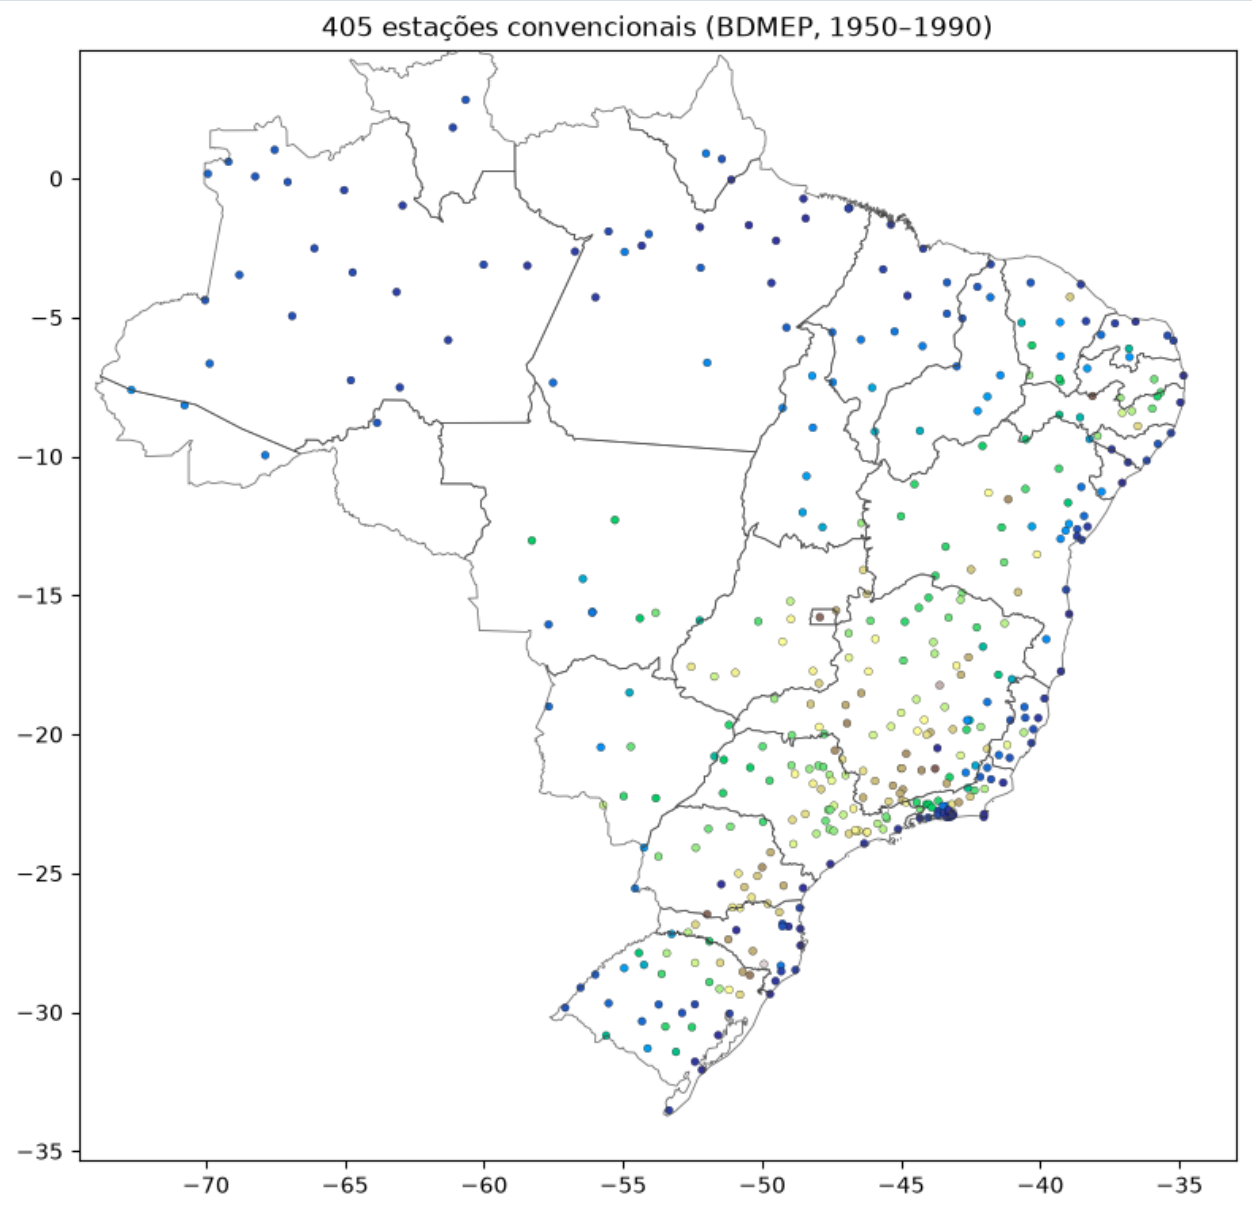


Figura 5. 405 estações convencionais utilizáveis (BDMEP, 1950–1990), coloridas por altitude.

Diagnóstico mês a mês da correção aplicada (erro médio e desvio-padrão em cada mês):

Mês	Erro T médio (°C)	Erro T DP (°C)	Correção média na grade (°C)
Jan	-0,03	0,88	0,00
Fev	-0,11	0,86	-0,08
Mar	-0,15	0,87	-0,12
Abr	-0,09	0,88	-0,09
Mai	0,11	0,91	0,10
Jun	0,32	0,98	0,40
Jul	0,37	1,06	0,51
Ago	0,39	1,11	0,63
Set	0,45	1,09	0,46
Out	0,28	1,00	0,46
Nov	0,00	1,03	0,14
Dez	-0,06	0,93	0,01

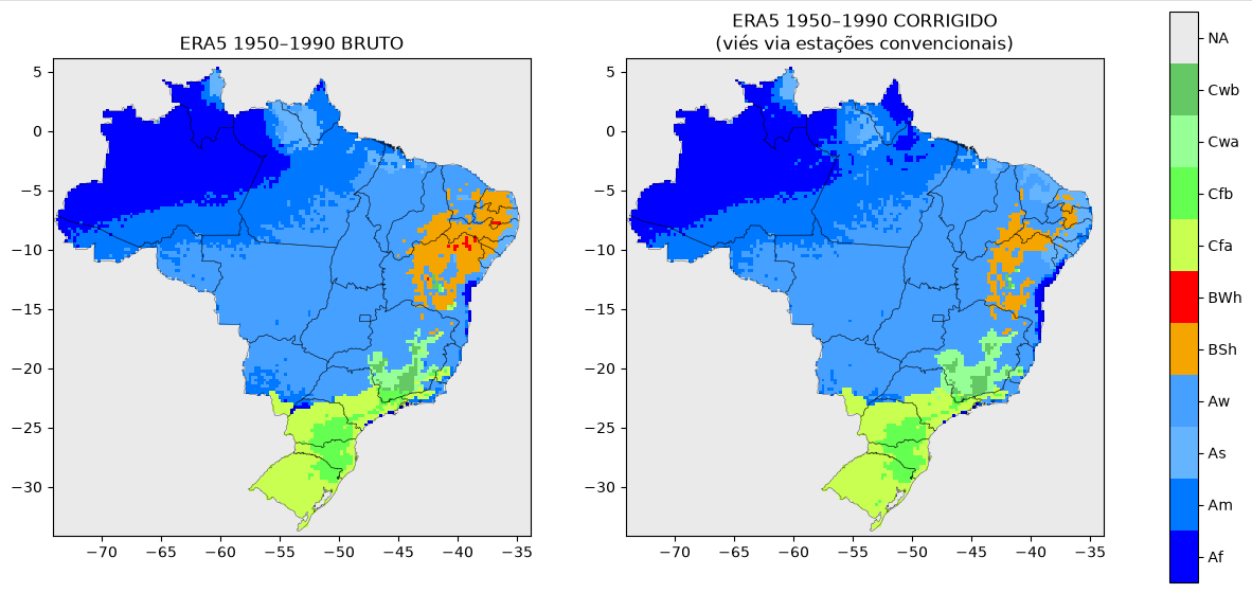


Figura 6. Comparação lado a lado: classificação ERA5 1950–1990 bruta vs. corrigida por estação.

7.2 Ganhos e perdas por tipo climático

Soma total de diferenças absolutas frente ao artigo: 36,9 pp (bruto) → 36,0 pp (corrigido) — melhora de menos de 1 ponto percentual. Mas esse número agregado esconde uma mistura real de ganhos e perdas por tipo:

Tipo	Artigo	ERA5 bruto	Dif. bruta (pp)	ERA5 corrigido	Dif. corrigida (pp)	Resultado
Am	27,5%	17,5%	-10,0	18,5%	-9,0	**melhorou**
Aw	25,8%	42,6%	+16,8	43,2%	+17,4	**piorou**
Af	22,6%	19,0%	-3,6	19,0%	-3,6	sem mudança
Cfa	6,5%	7,0%	+0,5	7,1%	+0,6	**piorou (marginal)**
As	5,5%	3,3%	-2,2	3,6%	-1,9	**melhorou**
BSh	4,9%	5,9%	+1,0	3,3%	-1,6	**piorou (supercorrigiu)**
Cfb	2,6%	2,7%	+0,1	2,4%	-0,2	**piorou (marginal)**
Cwa	2,5%	1,3%	-1,2	2,2%	-0,3	**melhorou bastante**
Cwb	2,1%	0,7%	-1,4	0,7%	-1,4	sem mudança

> **Avaliação:** a correção vale a pena manter como alternativa documentada, não como substituta definitiva do mapa bruto. O ganho mais sólido é em Cwa (-1,2 → -0,3 pp, melhora de 75%), mas Aw (o tipo dominante, principal responsável pela divergência total) e BSh pioraram. Além disso, a correção foi treinada e avaliada nos mesmos pontos de estação (sem separação treino/teste), então a melhora reportada é otimista.

8. Investigação: por que a correção não resolveu Am/Aw

O par Am/Aw sozinho responde por 26,8 dos 36,9 pontos percentuais de divergência total frente ao artigo — e a correção de viés mal tocou nele. Hipótese testada: a rede convencional tem um vazio de cobertura bem em cima da faixa de transição Amazônia-Cerrado, justamente onde essa fronteira mais importa.

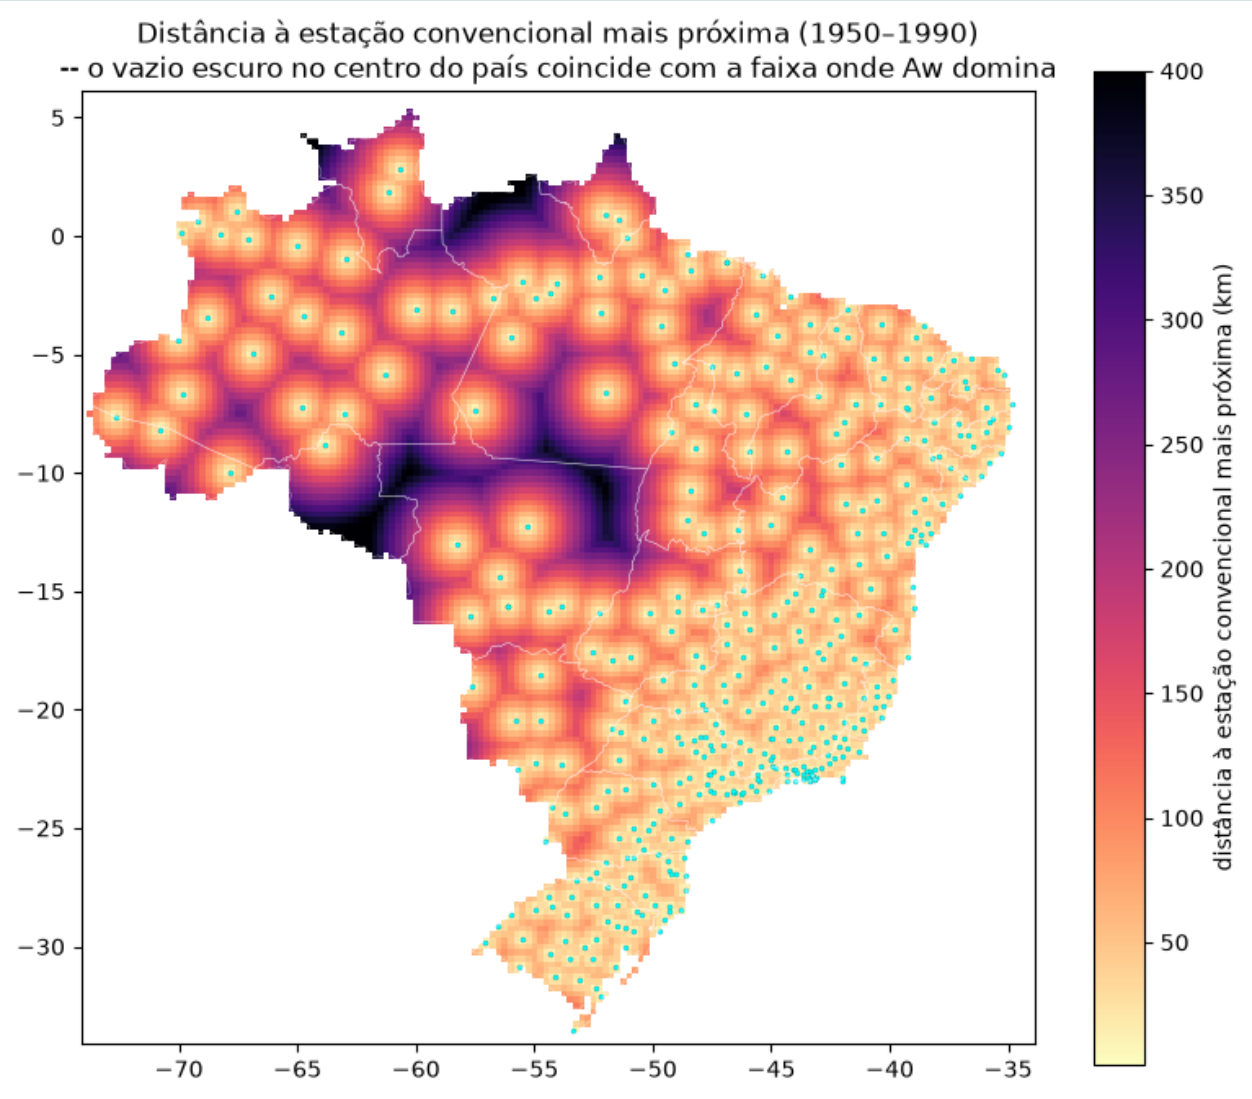


Figura 7. Esquerda: distância à estação convencional mais próxima (o vazio escuro no centro do país coincide com a faixa onde Aw domina). Direita: classificação resultante com as estações sobrepostas (x).

Tipo climático	Distância média à estação (km)	Distância mediana (km)
Cfb	34,8	33,8
Cwb	38,0	34,4
Cwa	39,2	38,7
Cfa	45,2	41,0
BSh	58,2	53,8
As	114,5	90,6
Aw	115,3	85,0
Af	131,7	119,6
Am	136,8	124,7

A proporção de Aw cresce de forma monotônica conforme a célula fica mais isolada de qualquer estação:

Distância à estação mais próxima	% do território	% Aw
> 100 km	42,5%	41,7%
> 150 km	24,9%	42,8%
> 200 km	14,1%	50,2%
> 250 km	8,3%	59,5%

> **Faixa de transição Amazônia-Cerrado (lat -6°/-14°, lon -58°/-48° — norte do MT, sul do PA/TO):** distância média à estação de 186 km, 69% maior que a média nacional (110 km). Composição climática ali: **82% Aw / 18% Am.** A krigagem do erro nessa região é essencialmente extrapolação de longo alcance, sem sinal local real para corrigir — por isso a correção de viés (Seção 7) não conseguiu mover essa fronteira.

9. Teste negativo: correção por taxa de lapso (altitude)

A divergência residual em Cwa/Cwb foi atribuída, em notebooks anteriores, à suavização de relevo do ERA5 em baixa resolução. Testamos uma correção por taxa de lapso (lapse-rate) antes de implementá-la — mesma técnica usada por WorldClim/CHELSA para downscaling de reanálise — e o resultado é negativo.

Preditor	Aplicável à grade?	Slope T médio (°C/100m)	R^2 médio (temperatura)	R^2 médio (precipitação)
Altitude real da estação (ponto)	**Não**	0,076	0,074	0,015
Diferença ponto−pixel	**Não**	0,205	0,132	0,009
Altitude média do pixel ERA5 (ETOPO)	**Sim**	0,023	0,010	0,023

> **Conclusão:** os preditores com sinal mais forte (R^2=0,07–0,13) só existem no ponto da estação — medem o descompasso entre um ponto específico e a média de área de ~28×28 km que o pixel ERA5 representa, não um viés sistemático corrigível em nível de grade (toda célula de saída já *é* uma média de área). O único preditor de fato aplicável à grade — altitude média do próprio pixel ERA5 — tem R^2≈0,01, insuficiente para justificar a implementação. Para precipitação o sinal é ainda mais fraco (R^2≈0,01–0,02 em todos os preditores). **A correção não foi implementada**; a causa da divergência residual em Cwa/Cwb fica como questão em aberto.

10. Limitações e ressalvas metodológicas

O algoritmo passa nos mesmos 15/15 testes sintéticos dos outros notebooks — as ressalvas abaixo são todas sobre os **dados de entrada**, não sobre a classificação.

- **Confiabilidade do ERA5 cai quanto mais se volta no tempo:** a densidade de observações assimiladas (radiossondas, estações de superfície, satélites — que só contribuem de forma relevante a partir de fins dos anos 1970) era muito menor nas décadas de 1950–60. O ERA5 é internamente consistente ao longo de todo o período, mas sua *acurácia* nos primeiros ~20 anos desta janela é inferior à dos últimos ~20 anos.
- **Bbox diferente entre os dois períodos ERA5:** o request de 1950–1990 usou uma bbox ligeiramente diferente do request de 1996–2025 (ambos a 0,25°, mas `[6,-74,-34,-34]` vs. `[5.25,-73,-33,-34]` aproximadamente) — por isso a comparação entre os dois períodos é agregada (Seção 6.4), não célula a célula.
- **Diferença de método permanece não isolada:** o artigo usa estações reais interpoladas por krigagem + regressão por altitude; mesmo rodando o ERA5 na mesma janela temporal, a diferença de método (reanálise de modelo numérico vs. observação direta interpolada) continua sendo uma variável separada da variável "período".
- **Correção de viés (Seção 7) quase não resolveu Am/Aw** e a Seção 8 explica por quê: vazio de cobertura de estação de até ~400 km de raio bem em cima da faixa de transição Amazônia-Cerrado.
- **A correção foi treinada e aplicada nos mesmos pontos de estação** (sem separação treino/teste) — a melhora reportada (36,9→36,0 pp) é uma medida otimista do que a correção consegue nos próprios pontos onde foi calibrada, não uma validação fora da amostra.
- **Correção por taxa de lapso testada e descartada (Seção 9):** sinal de altitude aplicável à grade é fraco demais ($R^2 \approx 0{,}01$) para justificar implementação.

11. Referências

ALVARES, C.A.; STAPE, J.L.; SENTELHAS, P.C.; GONÇALVES, J.L.M.; SPAROVEK, G. **Köppen's climate classification map for Brazil.** Meteorologische Zeitschrift, v. 22, n. 6, p. 711–728, 2013.

Copernicus Climate Change Service (C3S). **ERA5 monthly averaged data on single levels from 1940 to present.** Copernicus Climate Data Store (CDS), 2023.

Instituto Nacional de Meteorologia (INMET). **Banco de Dados Meteorológicos para Ensino e Pesquisa (BDMEP).** bdmep.inmet.gov.br

NOAA National Centers for Environmental Information. **ETOPO 2022 15 Arc-Second Global Relief Model.** 2022.

IBGE. **Malhas Geográficas — API de Malhas do IBGE.** servicodados.ibge.gov.br